

KUTATÁSI TERV

az Egyetemi Kutatói Ösztöndíj Program (EKÖP- 2025) keretében benyújtott pályázathoz

Pályázó neve: Berekméri Barna

A kutatási program címe: Hallgatói tanulmányi teljesítmény előrejelzése Random Forest algoritmussal

Egyetem: ELTE Informatikai Kar

A kutatandó téma összefoglalása

A hallgatói tanulmányi teljesítmény előrejelzése az oktatáskutatás és az adat vezérelt döntéstámogatás egyik kiemelt területe. Az oktatási intézmények számára a tanulmányi eredmények előrejelzése lehetőséget teremt a lemorzsolódás csökkentésére, a tanulási folyamatok hatékonyabb támogatására, valamint a személyre szabott oktatási beavatkozások tervezésére (Romero & Ventura, 2010).

A gépi tanulás különböző regressziós és osztályozási megközelítései széles körben alkalmazott eszközök a tanulmányi teljesítmény modellezésére. Ezek közül az ensemble módszerek különösen a Random Forest algoritmus kiemelt figyelmet kaptak, mivel képesek komplex, nemlineáris összefüggések kezelésére, és viszonylag robusztusak a zajos adatokkal szemben. (Breiman, 2001) munkája szerint a Random Forest módszer előnye, hogy több döntési fa együttes alkalmazásával csökkenti az egyedi modellek torzítását és varianciáját, ezáltal stabilabb előrejelzéseket eredményezhet.

Ugyanakkor a szakirodalom hangsúlyozza, hogy a prediktív modellek teljesítményét alapvetően az adatok minősége és a rendelkezésre álló jellemzők információtartalma határozza meg. Oktatási adathalmazok esetében gyakori probléma a hiányzó adatok jelenléte, a mérési hibák, valamint az, hogy a tanulmányi eredményeket befolyásoló tényezők egy része nehezen számszerűsíthető (Baker & Inventado, 2014).

Ezért kutatás nem csupán a modell teljesítményére fókuszál, hanem hangsúlyt fektet az adat-előkészítés, a jellemzők relevanciájának vizsgálata, valamint az eredmények értelmezésének módszertani kérdéseire is. Ezáltal a munka hozzájárul a prediktív modellezés lehetőségeinek és korlátjainak jobb megértéséhez az oktatási adatelemzés területén.

Kutatási terv és ütemezés

A kutatás célja egy olyan adatfeldolgozási és gépi tanulási elemzési keretrendszer kialakítása és értékelése, amely bemutatja a tanulmányi teljesítmény előrejelzésének lehetőségeit és korlátait zajos, szintetikus oktatási adatok esetén.

1. Irodalomkutatás és módszertani előkészítés

A hallgatói teljesítmény előrejelzésével kapcsolatos releváns szakirodalom feldolgozása, különös tekintettel a regressziós és ensemble alapú megközelítésekre.

2. Adathalmaz feltáró elemzése

A vizsgált adathalmaz statisztikai és vizuális elemzése, a zaj, hiányzó értékek és anomáliák azonosítása.

3. Adatelőkészítés és tisztítás

Hiányzó adatok kezelése, kategorikus változók kódolása, outlierok korrekciója, tanító- és teszhalmaz kialakítása.

4. Prediktív modellezés

Random Forest regressziós modell tanítása és konfigurálása, a modell működésének vizsgálata.

5. Modellértékelés és interpretáció

A modell teljesítményének értékelése standard regressziós mérőszámokkal (MAE, RMSE, R^2), valamint feature importance elemzés.

6. Eredmények összegzése és dokumentálása

A kapott eredmények értelmezése, a módszertani tanulságok összefoglalása.

Időszak	Tevékenység
1. hónap	Irodalomkutatás, módszertani előkészítés
2. hónap	Adathalmaz feltáró elemzése
3. hónap	Adattisztítás és előfeldolgozás
4. hónap	Modellépítés
5. hónap	Modellértékelés, elemzés
6. hónap	Dokumentáció és összegzés

Irodalomjegyzék

Breiman, L. (2001): Random forests. *Machine Learning*, 45(1), 5–32.

Romero, C. – Ventura, S. (2010): Educational data mining: A review of the state of the art. *IEEE Transactions on Systems, Man, and Cybernetics – Part C*, 40(6), 601–618.

Baker, R. S. – Inventado, P. S. (2014): Educational data mining and learning analytics. In: Larusson, J. A. – White, B. (szerk.): *Learning Analytics*. Springer, 61–75



Berekméri Barna



06 70 453 5226



barna.berekmeri@gmail.com



Budapest

Programtervező informatikus végzettségű adatbázis-fejlesztő, másfél éves szakmai tapasztalattal az Agrárközgazdasági Intézetnél. Python és PostgreSQL környezetben dolgozom. Adatok feldolgozásával majd ennek automatizálásával foglalkozom. Jelenleg az ELTE Információs rendszerek MSc hallgatója vagyok, érdeklődésem középpontjában az adatvezérelt megoldások és a hatékony informatikai rendszerek kialakítása áll.

Tanulmányok

ELTE IK Információs Rendszerek
MSc (2025-)
ELTE IK Programtervező
Informatikus BSc (2021-2025)

Informatikai ismeretek

- Programozás: Python
- Adatkezelés: pandas, PostgreSQL
- Web / backend: Django

Egyetemi projekt

- Oktatási adatok elemzése és előfeldolgozása
- Egyszerű prediktív modellek kipróbálása
- Modellkimenetek értelmezése

Készségek

- Angol nyelvtudás: B2 (középfokú)
- Német nyelv: alapfokú ismeretek
- Precíz munkavégzés
- Motivált, tanulásra nyitott hozzáállás

Tapasztalatok

AKI - AGRÁRKÖZGAZDASÁGI INTÉZET

Adatbázis-fejlesztő (2024 -)

- Strukturált adatok feldolgozása és elemzése Python és PostgreSQL segítségével
- Adatfeldolgozási és riportkészítési folyamatok automatizálása
- Együttműködés közgazdasági és elemzői csapatokkal
- Verziókezelő program használata

EGYÉB

Aquilon gyermektáboroztatás (2020 -)

- Kreatív megoldások
- Pedagógiai szemlélet
- Gyors helyzetfelismerés

Erasmus+ Project részvétel (2023)

- Tapasztalat többnyelvű kommunikációban
- Nemzetközi csapatmunka

Önkéntesség

Atlétikai Világbajnokság IT csapattag
Kollégiumi Diák Bizottság tagság